

Fase 2 | Avance de Proyecto

Materia: Operaciones de aprendizaje automático
Fecha de entrega: 2 de noviembre de 2025
TA: Luis Daniel Mendoza Morales

Equipo 9

Alejandro Caamaño Granados (A00843392)

Francisco Natanael Ortiz Martínez (A01796014)

Erika Cardona Rojas (A01749170)

Álvaro Daniel Zavala Arreola (A01796929)

Mariana Paola De los Cobos Kingston (A01796922)



Objetivo: Continuar con el desarrollo de proyectos de Machine Learning, a partir de los requerimientos, una propuesta de valor y un conjunto de datos preprocesados.

1. Estructuración de Proyectos con Cookiecutter
2. Estructuración y Refactorización del Código
3. Aplicación de Mejores Prácticas de Codificación en el Pipeline de Modelado
4. Seguimiento de Experimentos, Visualización de Resultados y Gestión de Modelos

Este conjunto de datos proviene del Insurance Company Benchmark (COIL 2000) de la UCI. Contiene 86 variables que describen datos socioeconómicos y de uso de productos de clientes asegurados.

1) Estructuración de Proyectos con Cookiecutter

- Proyecto organizado bajo la plantilla Cookiecutter Data Science:
 - data/raw, data/processed, notebooks/, src/, models/, reports/
- **Código modular:** cada etapa del flujo en una clase distinta (InsuranceDataProcessor, InsuranceEDA, InsurancePipeline, ModelTrainerEvaluator).
- Separación clara entre preprocesamiento, análisis, modelado y evaluación.
- Integración con MLflow en la etapa final del pipeline.

2) Estructuración y Refactorización del Código

Con el objetivo de optimizar la legibilidad, mantenibilidad y escalabilidad del código, se llevaron a cabo dos etapas de refactorización:

- **Primera refactorización: uso de funciones**

- + Se reorganizó el código original mediante la definición de funciones específicas para cada tarea.
- + Esta modularización permitió reducir la duplicación de código, facilitar la reutilización y mejorar la claridad del flujo lógico.

- **Segunda refactorización: implementación de programación orientada a objetos (OOP)**

- + Se transformó la estructura funcional en una arquitectura basada en clases.
- + Se diseñaron clases que encapsulan responsabilidades específicas, promoviendo una mayor cohesión y separación de preocupaciones.
- + Se incorporaron *pipelines* para estructurar el procesamiento de datos en etapas claramente definidas, lo que facilita la trazabilidad y el mantenimiento del sistema.

Estas mejoras no solo optimizan el rendimiento del código, sino que también lo preparan para futuras extensiones y adaptaciones.

3) Aplicación de Mejores Prácticas de Codificación en el Pipeline de Modelado

- **Implementación de un pipeline de Scikit-Learn:**
 - MedianOutlierHandler → limpia valores nulos y outliers.
 - CorrelationRemover → elimina variables altamente correlacionadas (>0.75).
 - StandardScaler → normaliza datos.
 - PCA → reducción de dimensionalidad (90% varianza explicada).
- **Buenas prácticas:**
 - Uso de POO (clases para cada etapa).
 - Modularidad y legibilidad del código.
 - Control de aleatoriedad (random_state=42) para reproducibilidad.
 - Balanceo de clases con SMOTE antes del entrenamiento.

4) Seguimiento de Experimentos, Visualización de Resultados y Gestión de Modelos

Continuamos con el uso de MLflow y DVC para el versionado y registro de datos y experimentos.

- **Implementación del Bucket de AWS S3**

- + Se reconfiguró DVC para guardar el dataset original "raw" en el bucket de AWS S3.
- + Se removió el localstorage que previamente se había establecido en local para DVC.

```
Windows PowerShell
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc init
ERROR: failed to initiate DVC - '.dvc' exists. Use '-f' to force.
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote add -d team_remote s3://itesm-mna/202502-equip09
Setting 'team_remote' as a default remote.
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote modify team_remote region us-east-2
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote modify team_remote profile equipo9
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> cat .dvc/config
[core]
  remote = team_remote
[remote "localstorage"]
  url = ../../local-dvc-storage
[remote "team_remote"]
  url = s3://itesm-mna/202502-equip09
  region = us-east-2
  profile = equipo9
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote remove localstorage
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote list
team_remote      s3://itesm-mna/202502-equip09  (default)
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> cat .dvc/config
[core]
  remote = team_remote
[remote "team_remote"]
  url = s3://itesm-mna/202502-equip09
  region = us-east-2
  profile = equipo9
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project>
```

```
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> aws s3 ls s3://itesm-mna/202502-equip09 --recursive --profile equipo9 | Select-Object -First 10
2025-09-30 17:43:04          0 202502-equip09/
2025-10-31 19:26:50    1012165 202502-equip09/files/md5/cb/7b84f0bddca9b624402bcc25720015
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project>
```

Roles y Colaboración:

- **Data Engineer - Álvaro Zavala**
 - Refactorización en archivos Python modulares y script principal.
- **Data Scientist - Paola De los Cobos**
 - Evaluación de 3 algoritmos (Regresión Logística, Random Forest y XGBoost)
 - Refactorización del código (Limpieza, EDA, FE, entrenamiento y evaluación)
- **Software Engineer - Erika Cardona**
 - Traducir la experimentación de Machine Learning en un sistema bien diseñado, documentado y reproducible.
- **ML Engineer - Francisco Ortiz**
 - Integración de MLFlow para el análisis de los experimentos dentro del flujo de trabajo.
 - Control de versiones de experimentos y código en el repositorio.
- **Site Reliability Engineer (DevOps) - Alejandro Caamaño**
 - Integración de Bucket de AWS S3 para registro de datos con DVC

Resultados

- Modelos entrenados con datos balanceados usando **SMOTE**.
- Métricas registradas con MLflow (accuracy, precision, recall, F1-score).
- Visualizaciones generadas:
 - + **Matriz de confusión** por modelo.
 - + **Reporte de clasificación** (resumen por clase).
 - + **Análisis PCA** mostrando el % de varianza explicada.
- Se identificó que los modelos con PCA y datos balanceados mejoraron la estabilidad de las predicciones.

Repositorio de GitHub

<https://github.com/a-caamano/mlops-project.git>

Conclusiones y reflexión final

- La estandarización con **Cookiecutter** y el uso de **pipelines modulares** mejora la mantenibilidad y escalabilidad.
- **MLflow** permitió un seguimiento claro de experimentos y resultados.
- La integración de **buenas prácticas (POO, SMOTE, PCA)** garantizó reproducibilidad y mayor calidad del modelo.
- Este enfoque demuestra cómo un flujo de *MLOps* facilita la colaboración y la trazabilidad del ciclo de vida del modelo.

Video

- https://drive.google.com/file/d/1AejN9kMTaGF1w_q0JAP_LjwjxSmG6ACI/view?usp=sharing