

Fase 1 | Avance de Proyecto

Alejandro Caamaño Granados (A00843392)

Francisco Natanael Ortiz Martínez (A01796014)

Erika Cardona Rojas (A01749170)

Álvaro Daniel Zavala Arreola (A01796929)

Mariana Paola De los Cobos Kingston (A01796922)



Objetivo: *Construir, ajustar y evaluar modelos de Machine Learning utilizando técnicas y algoritmos apropiados al problema.*

Este conjunto de datos proviene del Insurance Company Benchmark (COIL 2000) de la UCI. Contiene 86 variables que describen datos socioeconómicos y de uso de productos de clientes asegurados.

Análisis de Requerimientos

Problema por resolver:

- Predecir si un cliente adquirirá o no una póliza de vivienda móvil.

MLCanvas / propuesta de valor:

- Identificar clientes con alta probabilidad de compra permitirá optimizar campañas, reducir costos y mejorar la tasa de conversión.

Objetivo del modelo: Clasificación binaria.

- *Valor esperado:* Segmentar clientes con mayor potencial.

PREDICTION TASK  What is the type of task? <i>Clasificación supervisada</i> Which entity are predictions made on? <i>Cientes de una compañía de seguros</i> What are the possible outcomes to predict? <i>Una variable binaria, es decir, si el cliente comprará o no una póliza de seguro móvil.</i> When are outcomes observed? <i>A final de mes, posiblemente después</i>	DECISIONS  How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.) <i>Las probabilidades de compra de un seguro móvil se usan para:</i> <i>Seleccionar clientes con mayor probabilidad de adquirir un seguro</i> <i>Optimizar la inversión de presupuesto para campañas</i>	VALUE PROPOSITION  Who is the end beneficiary, and what specific pain points are addressed? How will the ML solution integrate with their workflow, and through which user interfaces? <i>Reducir bajas de seguro de vivienda móvil.</i> <i>Cada mes, compilar una lista de clientes sin seguro de vivienda móvil. Mandar correo promocional a todos estos clientes potenciales.</i>	DATA COLLECTION  How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)? What strategies are in place to update data continuously while controlling cost and maintaining freshness? <i>La colección inicial de datos se realiza por una extracción de un dataset. Para reducir costos y mantener actualizados los datos, enviar correos promocionales a 10% de los clientes predichos a no comprar el seguro. Añadir resultados a dataset.</i>	DATA SOURCES  Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.) <i>Datasets públicos (INEGI, etc.)</i> <i>Datos de clientes pasados</i> <i>Datos de clientes nuevos</i> <i>UCI KDD Archive</i>
IMPACT SIMULATION  What are the cost/gain values for (in)correct decisions? Which data is used to simulate pre-deployment impact? What are the criteria for deployment? Are there fairness constraints? <i>Pred. Clientes potenciales:</i> <i>Costo de error: bajo</i> <i>Ganancia: alta</i> <i>Pred. Clientes a rotar</i> <i>Costo de error: alto</i> <i>Ganacia: alta</i> <i>Criterios de despliegue</i> <i>Portabilidad</i> <i>Escalabilidad</i>	MAKING PREDICTIONS  Are predictions made in batch or in real time? How frequently? How much time is available for this (including featurization and decisions)? Which computational resources are used? <i>Batch predictions</i> <i>Predicciones una vez al mes</i> <i>Recursos computacionales</i> <i>Cloud computing (recomendado como prueba inicial)</i>	Preguntas a responder por ML: <i>¿Qué clientes son probables a comprar nuestro seguro?</i> <i>¿Qué clientes son probables a rotar (dar de baja nuestro seguro)?</i>	BUILDING MODELS  How many models are needed in production? When should they be updated? How much time is available for this (including featurization and analysis)? Which computation resources are used? <i>Deberíamos tener dos modelos en producción: uno para predecir clientes potenciales y otro para predecir clientes probables a dejar el seguro. Los modelos deben actualizarse cada mes, pero puede ser más tiempo si se trackea el input y model drift.</i>	FEATURES  What representations are used for entities at prediction time? What aggregations or transformations are applied to raw data sources? <i>85 features:</i> <i>Tipo de cliente</i> <i>Estado civil</i> <i>Nivel de estudios</i> <i>Ingresos</i> <i>Religión</i> <i># de autos, casas</i> <i># de seguros (de vida, auto, casa, incendio, etc.)</i>
	MONITORING Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business? How often should they be reviewed?	<i># de correos promocionales respondidos</i>	<i># de bajas de seguro</i> <i># de clientes nuevos</i>	

Manipulación y preparación de datos

Limpieza aplicada:

- Conversión de tipos de datos.
- Análisis de nulos y eliminación de columnas adicionales y con porcentaje elevado de nulos.

EDA inicial:

- Valores faltantes.
- Valores extremos (outliers).
- Histogramas de variables.
- Matriz de correlación de las variables.

Preprocesamiento y transformación de datos

Preprocesamiento:

- Eliminación de duplicados y registros con varios nulos
- División en train/test (80/20) para evitar data leakage
- Imputación de nulos y outliers con mediana
- Eliminación de variables altamente correlacionadas

Transformaciones:

- Normalización de variables.

Patrones detectados:

- Mayor probabilidad de compra en clientes con más productos financieros.
- Zonas urbanas con mayor tasa de adquisición.

Versionado de datos

Objetivo: Garantizar trazabilidad y reproducibilidad de los experimentos.

Acciones realizadas:

- Versionado de datasets con DVC (raw, clean, processed).
- Registro de métricas de limpieza y cambios con MLflow.

Beneficio:

Permite replicar los experimentos y evaluar el impacto de cada versión en el desempeño del modelo.

```

    dvc config core.autostage true
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> git add data/raw/insurance_company_original.csv.dvc .gitignore
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> git commit -m "Track insurance_company_original.csv using DVC"
[main bc1243c] Track insurance_company_original.csv using DVC
1 file changed, 5 insertions(+)
create mode 100644 data/raw/insurance_company_original.csv.dvc
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc push
Collecting |0.00 [00:00, ?entry/s]
Pushing
ERROR: failed to push data to the cloud - config file error: no remote specified in C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project. Create a default remote with
    dvc remote add -d <remote name> <remote url>
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc remote add -d localstorage ../local-dvc-storage
Setting 'localstorage' as a default remote.
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> git add .dvc/config
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> git commit -m "Configure DVC remote storage"
[main cca449d] Configure DVC remote storage
1 file changed, 4 insertions(+)
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> dvc push
Collecting |1.00 [00:00, 166entry/s]
Pushing
1 file pushed
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project> git push
Enumerating objects: 16, done.
Counting objects: 100% (16/16), done.
Delta compression using up to 12 threads
Compressing objects: 100% (10/10), done.
Writing objects: 100% (11/11), 1.15 KiB | 107.00 KiB/s, done.
Total 11 (delta 3), reused 0 (delta 0), pack-reused 0 (from 0)
remote: Resolving deltas: 100% (3/3), completed with 1 local object.
To https://github.com/a-caamano/mlops-project.git
56fd436..cca449d main -> main
(.venv) PS C:\Users\alex1\Documents\MLOps\mlops-project\mlops-project>

```

Construcción, ajuste y evaluación de Modelos de Machine Learning

- Algoritmos evaluados:
 - Regresión Logística (Logistic Regression).
 - Utilizamos este modelo para resolver el problema de clasificación binaria (cliente compra seguro o no).
- Entrenamiento y ajuste:
 - El modelo se configuró a un máximo de 500 iteraciones y se usó `class_weight='balanced'` para ajustar los pesos de las clases durante el entrenamiento.
- Métricas de evaluación:
 - Para evaluar el desempeño del modelo se calcularon las métricas:
 - ROC AUC
 - Accuracy
 - F1-Score
 -


Roles y Colaboración:

- **Data Engineer - Álvaro Zavala**
 - Limpieza de Datos.
 - Exploratory Data Analysis.
 - Soporte a otras áreas.
- **Data Scientist - Paola De los Cobos**
 - Limpieza de Datos
 - Exploratory Data Analysis
 - Feature Engineering
- **Software Engineer - Erika Cardona**
 - Preparación del entorno de trazabilidad
 - Integración de componentes
 - Soporte a otras áreas
- **ML Engineer - Francisco Ortiz**
 - Construcción y entrenamiento del modelo
 - Obtención y Análisis de métricas
 - Validación de resultados
- **Site Reliability Engineer (DevOps) - Alejandro Caamaño**
 - Creación de repositorio
 - Configuración del modelo en DVC
 - Registro de métricas de limpieza
 - Monitoreo de cambios en MLflow

Resultados

Los resultados del modelo están monitoreados a través de MLFlow para un correcto tracking. En estas primeras iteraciones, los resultados del modelo son:

Run complete — ROC AUC: 0.6271, Accuracy: 0.1964, F1: 0.1326



Repositorio de GitHub

https://github.com/a-caamano/mlops-project.git

 **mlops-project** Public

main

2 Branches

0 Tags

Go to file

t

Add file

<> Code

Pin

Watch 0

Fork 0

Star 0

 **a-caamano**

Rename Fase 1_MPDK.ipynb to Fase_1_MPDK.ipynb

56fd436 · 30 minutes ago · 12 Commits

.dvc

Add DVC files and functionality

yesterday

data/raw

Rename Data:Raw to data/raw

34 minutes ago

notebooks

Rename Fase 1_MPDK.ipynb to Fase_1_MPDK.ipynb

30 minutes ago

.dvcignore

Add DVC files and functionality

yesterday

.gitignore

Add initial requirements.txt and update .gitignore for venv e...

yesterday

README.md

Corrected markdown

yesterday

requirements.txt

Add initial requirements.txt and update .gitignore for venv e...

yesterday

README

About

Equipo 9 de MLOps

Readme

Activity

0 stars

0 watching

0 forks

Releases

No releases published

Create a new release

Packages

No packages published

Publish your first package

https://github.com/a-caamano/mlops-project/activity

Rename Fase 1_MPDK.ipynb to Fase_1_MPDK.ipynb

 a-caamano pushed 1 commit to **main** · 7371838...56fd436 · 6 hours ago

Rename Data:Raw to data/raw

 a-caamano pushed 1 commit to **main** · 8498f73...7371838 · 7 hours ago

Adds first version of model with MLFlow integration.

 a01796014 pushed 1 commit to **development** · aa266ef...bdd97d0 · 8 hours ago

Add files via upload

 A01796922 pushed 1 commit to **main** · 73c0a9c...8498f73 · 9 hours ago

Delete notebooks/.gitkeep

 A01796922 pushed 1 commit to **main** · b71a86f...73c0a9c · 9 hours ago

Add files via upload

 A01796922 pushed 1 commit to **main** · dee2e33...b71a86f · 9 hours ago

Create .gitkeep

 A01796922 pushed 1 commit to **main** · a2efbdd...dee2e33 · 9 hours ago

Adds ccdd structure

 a01796014 created **development** · aa266ef · 10 hours ago

Add files via upload

 eria017 pushed 1 commit to **main** · e96b590...a2efbdd · 17 hours ago

Corrected markdown

 a-caamano pushed 1 commit to **main** · 8a688e6...e96b590 · yesterday

All branches

All activity

All users

All time

Add files via upload

 jumpack1 pushed 1 commit to **main** · fd8cfe6...4b132f3 · 21 minutes ago

13

Conclusiones y reflexión final

- Áreas de oportunidad
 - Una de las principales áreas de oportunidad es el balanceo de clases.
 - También se podría probar con modelos más complejos (no lineales).
- Estrategias de análisis
 - Se realizó exploratory data analysis para observar correlación entre los features.
 - Se analizaron outliers y la distribución de los features.
 - Se realizó procesamiento de feature engineering para mapear algunos features y limpieza de valores nulos y redundantes para reducir dimensionalidad.

Video

- https://drive.google.com/drive/folders/1GBakNQxB_rM05pcl2CVZ38xr7boLQKqy?usp=sharing